

StreamView Analytics

Informe Ejecutivo — Etapa 1

Solución de Visual Analytics para el catálogo audiovisual de StreamView
Analytics

Felipe Ahumada Silva y Francisca Carrasco Lozano

ADY1104 — Visualización de Datos

1. Descripción del problema de negocio

StreamView Analytics es una plataforma de streaming digital que, tras un crecimiento acelerado en la cantidad de contenidos disponibles, enfrenta dificultades para transformar el gran volumen de información de su catálogo en conocimiento accionable. La organización dispone de datos suficientes para responder preguntas relevantes del negocio, pero la ausencia de una solución de visualización adecuada limita la capacidad de las distintas áreas para identificar tendencias, comparar contenidos y detectar oportunidades de mejora. Los dashboards existentes presentan problemas de diseño, exceso de información y poca interacción, lo que dificulta su uso para la toma de decisiones.

La Gerencia General solicitó explícitamente el desarrollo de una solución integral de Visual Analytics que permita explorar el catálogo mediante dashboards interactivos, visualizaciones especializadas y narrativas visuales orientadas a distintos niveles de decisión dentro de la organización.

2. Objetivos del proyecto

Objetivo general

Diseñar e implementar una solución integral de Visual Analytics que permita comunicar información relevante del catálogo audiovisual de StreamView Analytics mediante dashboards interactivos, narrativas visuales y productos gráficos que apoyen la toma de decisiones estratégicas.

Objetivos específicos

- Caracterizar el catálogo audiovisual de la organización.
- Analizar la distribución de contenidos por país, idioma, clasificación y género.
- Identificar tendencias de producción audiovisual.
- Comparar la popularidad y valoración de distintos contenidos.
- Analizar la relación entre presupuesto, ingresos y evaluación del público, para los contenidos donde esa información está disponible.
- Construir dashboards ejecutivos para distintos perfiles de usuario.
- Aplicar principios de percepción visual y storytelling para comunicar hallazgos.
- Formular recomendaciones sustentadas en evidencia.

3. Audiencia objetivo y propósito comunicacional

El caso identifica seis stakeholders con necesidades de información distintas (Directorio, Gerencia General, Gerencia de Contenidos y Adquisición, Gerencia de Marketing, Gerencia de Producto, y el Equipo de Data & Analytics). La solución no trata a esta audiencia como un bloque único, distintos productos de este proyecto priorizan a distintos perfiles:

- **La presentación ejecutiva** está diseñada para Directorio y Gerencia General, los únicos dos stakeholders que piden explícitamente “indicadores consolidados” y “recomendaciones ejecutivas” en lugar de un recorrido exhaustivo por cada corte de dato. Por eso profundiza en un solo hallazgo central en vez de repartir el tiempo entre ocho objetivos específicos.
- **El dashboard interactivo** sí cubre a los seis stakeholders, pero de forma jerárquica, no aplana toda la información en una sola vista, un selector de perfil (fusionado en 3 grupos, Directorio, Marketing y Data & Analytics, que a su vez absorben a Gerencia General, Contenidos y Adquisición, y Producto respectivamente) muestra a cada uno solo las secciones que su necesidad real justifica.

- El **notebook de análisis exploratorio** es el documento más técnico, pensado para el Equipo de Data & Analytics y para sustentar, con evidencia reproducible, cada afirmación que aparece en los otros dos productos.

El propósito comunicacional transversal es demostrar, con evidencia verificable y no con supuestos, que la popularidad de un contenido y su calificación de calidad son señales independientes, y que las decisiones de adquisición, promoción y desarrollo de catálogo deben tratarlas por separado.

4. Descripción de las fuentes de datos

El proyecto utiliza dos conjuntos de datos provistos por la organización, **Netflix Movies Detailed up to 2025** (16.000 películas, 18 columnas) y **Netflix TV Shows Detailed up to 2025** (16.000 filas antes de depuración, 16 columnas, 15.991 series únicas tras eliminar 9 registros duplicados por **show_id**). Ambos datasets comparten variables como título, director, elenco, país, idioma, año de estreno, géneros, popularidad, cantidad de votos y calificación promedio; **budget** y **revenue** solo existen en el dataset de películas.

Antes de cualquier análisis se auditó la calidad de cada variable (Sección 2 del notebook). Los hallazgos más relevantes de esa auditoría son:

- La columna **rating** coincide en el 100% de los registros con **vote_average**, no corresponde a la clasificación por edad que su nombre sugiere, y se excluyó del análisis.
- **budget** y **revenue** están en cero en 69,7% y 64,7% de las películas respectivamente, se tratan como dato ausente, no como valor real. Solo el 22,1% de las películas tiene ambos valores válidos, y ningún registro de series los tiene.
- Dentro de ese 22,1% con ambos valores, un 0,8% (30 películas) tiene una razón ingreso/presupuesto superior a 50 veces, incluyendo presupuestos idénticos (\$5) en títulos sin relación entre sí, un patrón compatible con error de captura del dato y no con un éxito financiero real (Sección 2.5). Se excluyen del gráfico de presupuesto vs ingresos del dashboard, a diferencia de los outliers de magnitud (Sección 2.11), que sí se conservan por corresponder a casos reales.
- El catálogo mantiene exactamente 1.000 películas y 1.000 series por cada año entre 2010 y 2024, con **date_added** coincidiendo con **release_year** en el 100% de los casos, un patrón artificialmente uniforme que impide interpretar el volumen anual como una tendencia real de crecimiento (ver Sección 5, Análisis exploratorio).
- **date_added** se almacena como texto, no como fecha, y requiere conversión antes de usarse.

5. Análisis exploratorio mediante visualizaciones

El análisis exploratorio completo vive en **notebooks/analisis_exploratorio.ipynb**, con 17 visualizaciones desarrolladas en Python (pandas, matplotlib), organizadas en un diagnóstico de calidad de datos, el cálculo de KPIs iniciales, y las visualizaciones propiamente tales, cada una respondiendo una pregunta de negocio concreta. Los indicadores de catálogo son:

31.991	16.000 / 15.991	147	83	24
Títulos totales	Películas / Series	Países	Idiomas	Géneros

La popularidad no depende de la calificación

Correlación prácticamente nula (películas $r=0.088$, series $r=-0.022$). Solo títulos con 10+ votos, muestra $n=3.000$.




Figura 1. Popularidad vs calificación, sin relación aparente entre ambas variables ($r=0,088$ en películas, $r=-0,022$ en series).

Hallazgo de calidad, el catálogo está distribuido de forma perfectamente uniforme

Exactamente 1.000 películas y 1.000 series por cada año (2010-2024); date_added coincide con release_year en el 100% de los registros. No es posible inferir una tendencia real de crecimiento con esta variable, el patrón sugiere una muestra curada con fines académicos.




Figura 2. Títulos por año de estreno, el catálogo mantiene un volumen casi idéntico cada año, evidencia de una muestra curada, no de crecimiento real.

Los géneros más populares son los peor evaluados

Calificación promedio por género (mín. 200 títulos). Talk (4,17) y Soap (5,19), líderes en popularidad, están entre los peor evaluados. Animation (6,71) e History (6,67) lideran calificación.




Figura 3. Calificación promedio por género. Talk (4,17) y Soap (5,19), los géneros con mayor popularidad, están entre los peor evaluados. Animation (6,71) e History (6,67) lideran calificación con una popularidad muy inferior.

6. Justificación de las representaciones gráficas seleccionadas

La selección de cada tipo de gráfico siguió el principio de usar el atributo visual más preciso para el tipo de comparación que la pregunta de negocio exige, en vez de elegir por estética:

- **Barras horizontales** para todos los rankings por categoría (género, país, idioma). La posición en un eje común es el atributo que el ojo humano compara con mayor precisión, y la orientación horizontal permite etiquetas de texto largas (nombres de países e idiomas) sin rotarlas.
- **Dispersión (scatter)** para la relación entre popularidad y calificación, es el único tipo de gráfico que muestra si dos variables continuas están o no relacionadas sin presuponer una tendencia.
- **Líneas** para las series de tiempo (calificación y volumen por año), preservan el orden temporal y hacen evidente la forma de la tendencia, incluida la caída artificial de 2025 por catálogo incompleto.
- **Un solo tono de color para “magnitud”** (rankings combinados que no separan película de serie) y **un color por rol** (azul para película, naranja para serie) únicamente en los gráficos que sí comparan ambos formatos. Mezclar ambos criterios en el mismo tablero generaba una lectura errónea, un ranking combinado en naranja se leía como “esto es de series” cuando en realidad mezclaba ambos tipos, error que se detectó y corrigió durante el desarrollo del dashboard.
- **Mediana en vez de promedio** para los rankings de popularidad por país e idioma, porque esa variable tiene outliers extremos conocidos (Sección 2.11) y un puñado de títulos virales puede definir un promedio sin representar al resto de la categoría. Se usa un mínimo de 200 títulos por categoría (**MIN_N**) para evitar que categorías con pocos datos distorsionen el ranking.

7. Desarrollo de la narrativa visual (Data Storytelling)

La presentación ejecutiva se construyó como un argumento, no como un recorrido temático. Abre con una pregunta sin responder (¿qué hace que un título sea popular en Netflix?), identifica explícitamente a su audiencia y por qué la eligió, caracteriza el catálogo con una lectura simple, revela el hallazgo central (la popularidad no depende de la calificación) como la bisagra de la charla, y lo sostiene con

cuatro evidencias independientes antes de cerrar con recomendaciones ejecutivas y la respuesta a la pregunta de apertura.

Las cuatro evidencias del hallazgo central

- El top 10 de popularidad lo dominan programas de conversación y telenovelas, no las películas mejor evaluadas.
- Los géneros más populares (Talk, Soap) son los peor evaluados; los mejor evaluados (Animation, History) tienen popularidad muy inferior.
- El top 10 por calificación (contenido de nicho) y el top 10 por cantidad de votos (blockbusters) no comparten un solo título.
- El mismo patrón se repite geográficamente, Filipinas casi triplica la popularidad típica de Estados Unidos, mientras que Japón lidera en calificación promedio, no en popularidad.

Cada hallazgo se verificó antes de incorporarse al relato, incluida una revisión adicional del caso de Filipinas y el tagalo, donde el 69% de las series en ese idioma tiene cero votos pese a una popularidad alta, un patrón real (no un error de datos) que refleja audiencias masivas sin participación en el sistema de calificación, y que se documentó como matiz metodológico en vez de ocultarse.

8. Diseño e implementación del dashboard interactivo

El dashboard se implementó en **Streamlit** (Python), en **dashboard/app.py**, reutilizando exactamente la misma limpieza de datos que el notebook para que ambos productos siempre reporten las mismas cifras. Se eligió Streamlit sobre una página HTML autocontenida porque reutiliza pandas directamente sin reimplementar en JavaScript la lógica de filtros y estadística robusta.

Filtros e indicadores

La barra lateral permite filtrar por tipo de contenido, año de estreno, país, idioma y género; todos los KPIs y gráficos se recalculan en vivo sobre el subconjunto filtrado. Una franja de 6 indicadores generales (títulos, películas/series, popularidad y calificación promedio, países/idiomas, géneros) se mantiene siempre visible, sin importar el perfil activo.

Jerarquía por perfil de usuario

Un selector de perfil (Directorio, Marketing, Data & Analytics) determina qué secciones se muestran, no es un simple reetiquetado visual, cada perfil ve un subconjunto real de contenido, más 2 a 4 indicadores propios calculados específicamente para su necesidad. El único bloque de contenido que dos perfiles comparten íntegramente es el top 10 de títulos, justificado porque Directorio lo usa como evidencia para recomendaciones y Marketing como indicador de contenidos populares, mismo dato, uso distinto.

Por qué cada indicador es adecuado para su perfil

Cada indicador y sección se seleccionó a partir de la necesidad textual de ese stakeholder en la Sección 9 del caso, no por disponibilidad de datos. La siguiente tabla deja esa trazabilidad explícita:

Perfil	Indicador / sección	Por qué es adecuado (Sección 9 del caso)
Directorio	Correlación popularidad-calificación	Necesidad textual, “comparaciones”. Es la comparación central del proyecto y sustenta la recomendación ejecutiva principal.

Perfil	Indicador / sección	Por qué es adecuado (Sección 9 del caso)
Directorio	% películas con datos financieros válidos	Necesidad textual, “apoya decisiones de inversión y crecimiento”.
Directorio	País y género con más títulos (panorama)	Necesidad de Gerencia General (absorbida en este perfil), “visión global del catálogo para la planificación estratégica”.
Directorio	Presupuesto vs ingresos	Misma necesidad de inversión y crecimiento, con el detalle título por título.
Marketing	Título más popular	Necesidad textual, literalmente “contenidos más populares”.
Marketing	País / idioma con mayor popularidad típica	Necesidad de Contenidos y Adquisición (absorbida en este perfil), “identificar países... con mayor potencial estratégico”.
Marketing	Género mejor evaluado	Misma necesidad, “identificar géneros... con mayor potencial estratégico”, deliberadamente no es el género más frecuente (ver Sección 7).
Marketing	Volumen por año (no calificación por año)	Necesidad textual, “evolución temporal del catálogo”, se prefirió sobre la tendencia de calificación por describir mejor la composición cambiante, no la calidad, del catálogo.
Data & Analytics	Series duplicadas removidas	Necesidad textual, “asegurar la calidad de la información presentada”.
Data & Analytics	% presupuesto/ingresos válidos	Misma necesidad, declarar la cobertura real del dato antes de usarlo.
Data & Analytics	Todas las secciones sin recorte	Necesidad textual, “mantener los dashboards corporativos”, requiere visibilidad completa para poder auditarlos y mantenerlos.

9. Evaluación crítica de la solución desarrollada

Fortalezas

- Cada afirmación del proyecto se verificó contra los datos antes de publicarse, no se redactó ningún hallazgo de memoria, varias correcciones ocurrieron precisamente porque una primera lectura no coincidía con lo que los datos mostraban al graficarse (el caso más claro es la aparente tendencia de crecimiento del catálogo, que resultó ser una muestra uniforme).
- Consistencia numérica entre los tres productos (notebook, dashboard, presentación), todos calculan desde los mismos CSV originales con la misma lógica de limpieza, sin un archivo intermedio que pueda desincronizarse.
- Uso de estadística robusta donde correspondía (mediana en vez de promedio para variables con outliers conocidos) en lugar de aplicar promedio de forma automática.
- La solución diferencia explícitamente a seis stakeholders con necesidades de información distintas, en vez de tratar a toda la organización como una sola audiencia.

Limitaciones

- El catálogo es una muestra curada con fines académicos (1.000 películas y 1.000 series por año, de forma artificial), no permite inferir tendencias reales de crecimiento ni generalizarse a un catálogo de producción.
- Los datos financieros solo están disponibles y son confiables para el 22,1% de las películas, y no existen en absoluto para series, cualquier análisis de rentabilidad queda necesariamente incompleto.

- El dataset no incluye información de comportamiento real de usuarios (reproducciones, tiempo visto, suscripciones), **popularity** es un índice propio de la fuente de datos (no acotado a una escala fija, en este catálogo va de 2,3 a 6.421,9) que combina señales de tendencia, no una medición directa de audiencia de StreamView Analytics.
- La columna **rating** no pudo usarse como clasificación por edad al no corresponder a esa variable, dejando ese objetivo del caso (“analizar por clasificación”) fuera de alcance por ausencia de un dato confiable, no por decisión de diseño.

Oportunidades de mejora

- Incorporar datos reales de reproducciones e interacción de usuarios permitiría contrastar el índice de popularidad de la fuente con el consumo efectivo dentro de la plataforma.
- Desplegar el dashboard en un servicio accesible de forma permanente (por ejemplo, Streamlit Community Cloud) en vez de depender de una ejecución local, facilitaría su uso continuo fuera de la instancia de evaluación.
- Ampliar el análisis financiero cuando existan datos de presupuesto e ingresos más completos, hoy el 77,9% de las películas y el 100% de las series quedan fuera de ese análisis por ausencia de dato, no por elección metodológica.

10. Conclusiones y recomendaciones

La evidencia reunida en este proyecto sustenta una conclusión central, popularidad y calidad son métricas independientes en el catálogo de StreamView Analytics, y deben tratarse como tales en cualquier decisión de negocio. Esto se sostiene en cuatro líneas de evidencia independientes, el ranking de contenidos, el desempeño por género, el contraste entre nicho y blockbuster, y el mismo patrón repetido geográficamente.

Recomendaciones

- No usar **vote_average** como proxy de éxito de un contenido, mide una dimensión distinta a la que realmente consume la audiencia.
- La estrategia de adquisición y promoción debería observar popularidad y calificación por separado, no combinadas en un solo puntaje, un contenido puede ser estratégicamente valioso por cualquiera de las dos razones, no solo por ambas a la vez.
- El contenido de nicho (bien evaluado, poco popular) y el contenido viral (muy popular, mal evaluado) requieren objetivos de negocio distintos, prestigio y retención de audiencia de calidad en el primer caso, alcance y visibilidad en el segundo.
- Cualquier análisis financiero debe declarar explícitamente su cobertura real (22,1% de las películas, 0% de las series) para no proyectar conclusiones de rentabilidad sobre el catálogo completo.